7 Aula 07 — Introdução ao 1º Teorema de Shannon

7.1 Propriedades da entropia

Teorema 1 (Propriedades da entropia)**.** Seja $X = (x, A, P)$ um ensemble.

a) **Não-negatividade.** Temos sempre que $0 < H(x)$, excepto quando x é constante (i.e. quando $\Pr[x = a] = 1$ para algum $a \in A$), e nesse caso $H(x) = 0$.

b) **Limite Superior.** Temos sempre $H(x) < \log |A|$, excepto quando x é uniformemente distribuida em A, e nesse caso $H(x) = \log |A|$.

c) Se $((x, y), A \times B, P)$ é um ensemble de tuplos e x e y são independentes, então
$$H(x, y) = H(x) + H(y).$$

Demonstração. (a) A não negatividade surge do facto que $\log \frac{1}{p} \geq 0$ sempre que $p \in (0, 1]$. Temos também que $\log \frac{1}{p} > 0$ sempre que $p \in (0, 1)$ e $\log \frac{1}{1} = 0$, logo $H(x) = 0$ sse existir um $a \in A$ tal que $P(a) = 1$.
(b) Utilizamos o facto que a função $\log x$ é estritamente côncava no intervalo $[0, 1]$. Deste facto e da desigualdade de Jensen derivamos que

$$H(x) = \mathbb{E}\left[\log \frac{1}{P(a)}\right] \leq \log \mathbb{E}\left[\frac{1}{P(a)}\right] = \log |A|$$

com igualdade sse $\frac{1}{P(a)}$ for constante, o que por sua vez acontece sse x for uniformemente distribuida em A.
(c) Temos que

$$\begin{aligned}
H(x, y) &= \sum_{a,b} P(a, b) \log \frac{1}{P(a, b)} \\
&= \sum_{a,b} P(a)P(b) \log \frac{1}{P(a)P(b)} \\
&= \sum_{a,b} P(a)P(b) \log \frac{1}{P(a)} + \sum_{a,b} P(a)P(b) \log \frac{1}{P(b)} \\
&= \sum_{a} P(a) \log \frac{1}{P(a)} + \sum_{b} P(b) \log \frac{1}{P(b)} \\
&= H(x) + H(y)
\end{aligned}$$

□

7.2 Porque é que a quantidade de informação é $\log \frac{1}{p}$?

É razoável esperar que, seja qual for a função I escolhida o seguinte aconteça:

- $I(E)$ depende apenas da probabilidade $P(E)$, ou seja, existe uma função f tal que $I(E) = f(P(E))$.
- Se E é um evento com $\Pr[E] = 1$, então $I(E) = 0$. Ou seja, $f(1) = 0$.
- $I(E) \geqslant 0$ para todo o evento E. Ou seja, $f(p) \geqslant 0$ para todo o $p \in \{0, 1\}$.
- Se dois eventos são independentes, então $I(E_1 \cap E_2) = I(E_1) + I(E_2)$. Ou seja

Teorema 2 (Não vamos mostrar)**.** As únicas funções f que satisfazem os requisitos acima são as funções da forma

$$f(p) = \log_b \frac{1}{p}$$

em que $b \geqslant 0$ é a base do logaritmo.

Quando escolhemos a base $b = 2$, obtemos uma medida da quantidade de informação numa unidade que Shannon designou por "bit". Um "bit", tradução literal, um "pedaço" de informação

Exemplo 3. Seja x uniformemente escolhido entre 1 e 64, inclusivé. Qual é a quantidade de informação que aprendemos ao descobrir qual foi o resultado? Qual é a entropia de x?

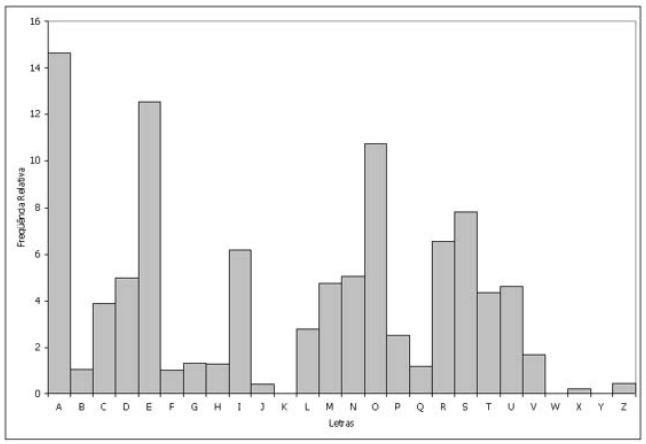
Quantas perguntas sim/não é necessário fazer para descobrir qual foi o número escolhido?

Exemplo 4. Exemplo da batalha naval com um submarino.

Fazemos pergunta a pergunta, explicar quanta informação é que aprendemos com cada nova resposta.

Quanta informação aprendêmos ao acertar? Quanta informação aprendemos se 32 respostas foram negativas?

Exemplo 5. Exemplo das letras em Português.



Frequência das letras em Português

7.3 Compressão de dados

Exemplo 6. Os ficheiros em disco são guardados em bytes. Um byte consegue guardar um valor entre 0 e 255, mas só existem 128 caracteres ASCII.

Se sabemos que um ficheiro com N bytes só usa caracteres ASCII, como é que podemos comprimir o ficheiro? Quantos bytes são de facto necessários para o guardar? Qual seria um bom algoritmo de compressão / descompressão?

Suponhamos que temos um processo aleatório, cujo resultado é dado por uma variável aleatória $x \in A$, e queremos guardar x na memória de um computador. Quanta memória é necessária?

Uma forma de o fazer é enumerando os elementos de A que tenham probabilidade positiva,

$$\{a \in A \mid P(a) > 0\} = \{a_1, \ldots, a_N\},$$

e representar o resultado $x = i$ pelo número i escrito em binário. Podemos então definir uma medida da "quantidade de informação" de x:

$$H_0(x) = \log |\{a \in A \mid P(a) > 0\}|.$$

Nota. Já vimos que temos sempre que $H(x) \leq H_0(x)$.

Exercício 7. É possível desenhar um compressor que representa cada um dos resultados $x = a$ possíveis de forma que todos os resultados sejam representados com menos de $H_0(x)$ bits?

A resposta é **não**. Só existem duas maneiras de um compressor comprimir uma fonte x:

- *Compressão de comprimento variável.* Ou comprime certas mensagens para palavras mais pequenas, mas outras mensagens serão comprimidos para palavras maiores. Irêmos ver exemplos de compressores deste género para a semana.

- *Compressão com perdas.* Ou é um compressor *com perdas*, no sentido que pode "comprimir" mensagens diferentes para o mesmo valor, ou que podem haver certas mensagens que o compressor não sabe representar. O primeiro tipo de compressor é aceitável em certos cenários (por exemplo em compressão de audio, ou de imagem), mas nesta cadeira vamos apenas considerar o segundo cenário em que queremos sempre recuperar a mensagem original sem defeitos dado a sua versão comprimida, mas aonde poderão haver certas mensagens que não sabemos comprimir. Então sempre que consideramos um compressor com perdas, interessa-nos o parâmetro δ que é a probabilidade de obtermos uma mensagem que não sabemos comprimir.