8 Aula 08 — 1º Teorema de Shannon (2)

8.1 Compressão com perdas (§4.3 do livro)

Suponhamos agora que estamos dispostos a utilizar um compressor com perdas. Ou seja, quando a mensagem x é escolhida de acordo com um dado ensemble (x, A, P), poderá haver alguma probabilidade $\delta > 0$ de não sabermos como codificar a mensagem. Dado δ, queremos minimizar o tamanho da palavra-código.

Exemplo 1. Consideremos o ensemble (x, A, P) com

A	a	b	c	d	e	f	g	h
$P(x)$	$1/4$	$1/4$	$1/4$	$3/16$	$1/64$	$1/64$	$1/64$	$1/64$

Temos que $H_0(x) = \log 8 = 3$ bits, mas observando que $\Pr[x \in \{e, f, g, h\}] = \frac{1}{16}$, concluímos o seguinte: se estivermos dispostos a correr o risco, com probabilidade $\delta = 1/16$, de não ser capazes de codificar x, então podemos utilizar apenas $\log 4 = 2$ bits.

Podemos também calcular:

$$\begin{aligned} H(x) &= \frac{3}{4} \cdot \log 4 + \frac{3}{16} \cdot \log \frac{16}{3} + \frac{4}{64} \cdot \log 64 \\ &= \frac{3}{4} \cdot 2 + \frac{3}{16} \cdot \log \frac{16}{3} + \frac{1}{16} \cdot 6 \\ &\approx 2.33 \text{ bits} \end{aligned}$$

Podemos formalizar esta ideia da seguinte forma:

Definição 2. Seja dado um ensemble $X = (x, A, P)$. Um conjunto $E \subseteq A$ diz-se *δ-suficiente* se

$$P(E) \geq 1 - \delta.$$

Seja S_δ o tamanho mais pequeno possível de um conjunto δ-suficiente. Definimos então

$$H_\delta(x) = \log S_\delta.$$

Nota. Se tivermos $A = \{a_1, \ldots, a_n\}$ com $P(a_1) \geq P(a_2) \geq \cdots \geq P(a_n)$, então

$$S = \min \left\{ i \in [n] \;\middle|\; \sum_{j \leq i} a_j \geq 1 - \delta \right\}.$$

Exemplo 3. Consideremos a distribuição binomial, em que fazemos n lançamentos independentes de moedas $x_1, \ldots, x_n$ com $\Pr[x_i = 1] = \frac{1}{10}$.

Temos então

$$H(x_1, \ldots, x_n) = nH(x_i) = nH_2(p) \approx 0.46 \cdot n.$$

$$H_0(x_1, \ldots, x_n) = n.$$

Vamos computar à mão o caso $n = 2$: $H_\delta(x_1, x_2)$.

E agora podemos traçar os gráficos de $H_\delta(x_1, \ldots, x_n)$ para $n = 1, 2, 10$,*etc.*

Sugestão de TPC: fazer um programa para computar os gráficos mostrados.

Observação interessante: Seja qual for o $\delta > 0$ que fixarmos, parecemos ter que

$$\lim_{n\to\infty} \frac{1}{n} H_\delta(x_1, \ldots, x_n) = H(\frac{1}{10})!$$

De facto vamos mostrar que isto é verdade.

Definição 4. Dado um ensemble $X = (x, A, P)$, seja $X^n = ((x_1, \ldots, x_n), A^n, P')$ o ensemble obtido repetindo independentemente n vezes a experiência aleatória que gera x. Ou seja,

$$P'(x_1, \ldots, x_n) = P(x_1) \cdots P(x_n).$$

Teorema 5 ((metade do) Primeiro teorema de Shannon)**.** Seja $X = (x, A, P)$ um ensemble, e tomemos uma constante $\delta \in (0, 1)$ qualquer. Então temos que

$$\lim_{n\to\infty} \frac{1}{n} H_\delta(x_1, \ldots, x_n) = H(x),$$

em que $x_1, \ldots, x_n$ são dados pelo ensemble X^n.

8.2 Trabalho informal na direcção da demonstração

Suponhamos que temos n variáveis independentes $x_1, \ldots, x_n$ cada uma obtida pela mesma distribuição.

Exemplos: n lançamentos da mesma moeda enviesada, n lançamentos do mesmo dados posivelmente enviesado, n letras (escolhidas independentemente e com a mesma distribuição), n mensagens a serem transmitidas/armazenadas/etc.

Qual é, em média, a quantidade de informação que aprendemos com $x_1, \ldots, x_n$? É exactamente $H(x_1, \ldots, x_n)$ que é igual a $n \cdot H$, em que $H = H(x_i)$, porque x_i são independentes.

E qual é o desvio padrão da quantidade de informação que aprendemos com $x_1, \ldots, x_n$? Podemos calcular:

$$\begin{aligned}
\mathsf{var}\left[\log \frac{1}{P(x_1, \ldots, x_n)}\right] &= \mathsf{var}\left[\sum_{i=1}^{n} \log \frac{1}{P(x_i)}\right] \\
&= \sum_{i=1}^{n} \mathsf{var}\left[\log \frac{1}{P(x_i)}\right] \\
&= N \cdot \sigma^2
\end{aligned}$$

em que V é a variância da quantidade de informação de cada x_i individualmente:

$$\sigma^2 = \mathbb{E}\left[\left(\log \frac{1}{P(x_i)} - H\right)^2\right].$$

O desvio padrão, portanto, é

$$\mathsf{dev}\left[\log \frac{1}{P(x_1,\ldots,x_n)}\right] = \sqrt{N}\cdot\sigma$$

Temos então, pela desigualdade de Chebyshev, que

$$\Pr\left[\log \frac{1}{P(x_1,\ldots,x_n)} \geq N\cdot H + k\cdot\sqrt{N}\cdot\sigma\right] \leq \frac{1}{k^2}$$

Quando N e k são suficientemente grandes, concluímos que, para a maioria dos valores de $x_1,\ldots,x_n$, a quantidade de informação que aprendemos por cada um dos valores é muito próxima de N vezes H.

Vamos ver isto com cuidado na próxima aula, mas fazemos agora uma primeira vez para depois ditar formalmente na próxima aula.

Em particular, para todo o $\varepsilon,\delta > 0$ podemos escolher $k = \frac{1}{\sqrt{\delta}}$, e $N = \frac{\sigma}{\delta\varepsilon}$, e então concluímos que

$$\Pr\left[\log \frac{1}{P(x_1,\ldots,x_n)} \geq N\cdot(H+\varepsilon)\right] \leq \delta.$$

Se definirmos então o conjunto:

$$T = \left\{(a_1,\ldots,a_n)\in A^n \mid \log\frac{1}{P(x_1,\ldots,x_n)} \geq N(H+\varepsilon)\right\}$$

vemos que $\Pr[(x_1,\ldots,x_n)\notin T]\leq\delta$. No entanto,

$$|T| \leq 2^{N(H+\varepsilon)},$$

logo

$$H_\delta(x_1,\ldots,x_n) \leq H+\varepsilon.$$

No limite quando ε tende para zero vemos o resultado.