9 Aula 09 — 1º Teorema de Shannon (completo e rigorosamente demonstrado)

Teorema 1 (Primeiro teorema de Shannon, informal)**.** É possível comprimir o resultado de n variáveis aleatórias $x_1, \ldots, x_n$ independentes e idênticamente distribuidas, cada uma com entropia $H(x_i) = H$, utilizando NH bits, de modo a que o erro de compressão se aproxima de 0 quando $N \to \infty$. Por outro lado, qualquer esquema de compressão que utilize $N(H - \varepsilon)$ bits resultará de um erro de transmissão.

Para formalizar o teorema, vamos relembrar a definição de δ-suficiência.

Definição 2. Seja dado um ensemble $X = (x, A, P)$. Um conjunto $E \subseteq A$ diz-se *δ-suficiente* para x se

$$P(E) \geq 1 - \delta.$$

Seja $S_\delta(x)$ o tamanho mais pequeno possível de um conjunto δ-suficiente para x. Definimos então

$$H_\delta(x) = \log S_\delta(x).$$

Nota. Como vimos na aula passada, $H_\delta(x)$ é o número mínimo de bits que precisamos de utilizar para transmitir x com erro δ.

Teorema 3 (Primeiro teorema de Shannon, formal)**.** Seja $X = (x, A, P)$ um ensemble, e tomemos uma constante $\delta \in (0, 1)$ qualquer. Então temos que

$$\lim_{n \to \infty} \frac{1}{n} H_\delta(x_1, \ldots, x_n) = H(x),$$

em que $x_1, \ldots, x_n$ são escolhidos independentemente com a mesma distribuição de x. Ou seja, são dados pelo ensemble $X^n = ((x_1, \ldots, x_n), A^n, P')$, com

$$P'(a_1, \ldots, a_n) = P(a_1) \cdots P(a_n).$$

Demonstração. Seja H a quantidade de informação média de x, isto é,

$$H = \mathbb{E}\left[\log \frac{1}{x}\right] = H(x).$$

E seja σ^2 a variância da quantidade de informação de x, portanto,

$$\sigma^2 = \mathbb{E}\left[\left(\log \frac{1}{P(x)} - H\right)^2\right].$$

Tomemos portanto n variáveis aleatórias $x_1, \ldots, x_n$, independentes e idênticamente distribuidas, com a mesma distribuição de x.

Temos então que a quantidade de informação média de $x_1, \ldots, x_n$ é:

$$H(x_1, \ldots, x_n) = \mathbb{E}\left[\frac{1}{\log(P(x_1, \ldots, x_n))}\right] = nH$$

Temos também que a variância da quantidade de informação de $x_1, \ldots, x_n$ é:

$$\begin{aligned}\mathsf{var}\left[\log \frac{1}{P(x_1,\ldots,x_n)}\right] &= \mathsf{var}\left[\sum_{i=1}^{n} \log \frac{1}{P(x_i)}\right] \\ &= \sum_{i=1}^{n} \mathsf{var}\left[\log \frac{1}{P(x_i)}\right] \\ &= n \cdot \sigma^2\end{aligned}$$

O desvio padrão da quantidade de informação de $x_1, \ldots, x_n$, portanto, é

$$\mathsf{dev}\left[\log \frac{1}{P(x_1,\ldots,x_n)}\right] = \sqrt{n} \cdot \sigma$$

- Temos então, pela desigualdade de Chebyshev, que para todo o k,

$$\Pr\left[\log \frac{1}{P(x_1,\ldots,x_n)} > n \cdot H + k \cdot \sqrt{n} \cdot \sigma\right] < \frac{1}{k^2}$$

Por outras palavras, concluímos que

$$\Pr\left[P(x_1,\ldots,x_n) < 2^{-n\cdot(H+\frac{k\cdot\sigma}{\sqrt{n}})}\right] < \frac{1}{k^2}$$

Por outras palavras, consideremos o evento $T_k \subseteq A^n$:

$$T_k = \left\{(a_1,\ldots,a_n) \in A^n \;\middle|\; P(x_1,\ldots,x_n) \geq 2^{-n\cdot(H+\frac{k\cdot\sigma}{\sqrt{n}})}\right\}.$$

Temos então que

$$\Pr[(x_1,\ldots,x_n) \in T_k] \geq 1 - \frac{1}{k^2}.$$

Ora, se escolhermos $T = T_k$ com $k = \sqrt{\frac{1}{\delta}}$, concluímos que

$$\Pr[(x_1,\ldots,x_n) \in T] \geq 1 - \delta.$$

Ou seja, T é δ-suficiente para $x_1, \ldots, x_n$.

Repare-se agora que $P(T) \leq 1$, mas cada elemento $(a_1, \ldots, a_n) \in T$ tem probabilidade pelo menos

$$P(a_1,\ldots,a_n) \geq 2^{-n\cdot(H+\frac{\sigma}{\sqrt{\delta n}})},$$

logo podemos concluir que

$$|T| \leq 2^{n\cdot(H+\frac{\sigma}{\sqrt{\delta n}})}.$$

E então, visto que $S_\delta(x_1,\ldots,x_n) \leq |T|$, temos

$$H_\delta(x_1,\ldots,x_n) = \log S_\delta(x_1,\ldots,x_n) \leq n \cdot \left(H + \frac{\sigma}{\sqrt{\delta n}}\right).$$

Concluímos portanto que

$$\frac{1}{n}H_\delta(x_1,\ldots,x_n) \leq H + \frac{\sigma}{\sqrt{\delta n}}.$$

- Vamos mostrar que

$$\frac{1}{n}H_\delta(x_1,\ldots,x_n) \geq H - 4\frac{\sigma}{\sqrt{\delta n}},$$

ou seja, que qualquer conjunto S que seja δ-suficiente para $x_1,\ldots,x_n$, vai ter necessáriamente

$$|S| \geq 2^{n(H-4\frac{\sigma}{\sqrt{\delta n}})}.$$

Mostrêmos isto por contrapositiva, ou seja, mostremos que qualquer conjunto mais pequeno não pode ser δ-suficiente. Suponhamos então que existe um conjunto $I \subseteq A^n$, com

$$|I| \leq 2^{n(H-4\frac{\sigma}{\sqrt{\delta n}})} = 2^{nH-4\frac{1}{\sqrt{\delta}}\sigma\sqrt{n}}.$$

A desigualdade de Chebyshev também nos diz que, para todo o k,

$$\Pr\left[\log\frac{1}{P(x_1,\ldots,x_n)} < n\cdot H - k\cdot\sqrt{n}\cdot\sigma\right] < \frac{1}{k^2}$$

Por outras palavras, consideremos o evento $U_k \subseteq A^n$:

$$U_k = \left\{(a_1,\ldots,a_n)\in A^n \;\middle|\; P(x_1,\ldots,x_n) \leq 2^{-nH+k\cdot\sigma\sqrt{n}}\right\}.$$

Temos então que

$$\Pr[(x_1,\ldots,x_n)\in U_k] \geq 1 - \frac{1}{k^2}.$$

Seja $U = U_k$ com $k = \frac{2}{\sqrt{\delta}}$, de modo a que $P(U_k) \geq 1 - \frac{\delta}{4}$. Temos então

$$P(U) = \left\{(a_1,\ldots,a_n)\in A^n \;\middle|\; P(x_1,\ldots,x_n) \leq 2^{-nH+2\frac{1}{\sqrt{\delta}}\sigma\sqrt{n}}\right\}.$$

$$\begin{aligned} I &= (I\cap U_k)\cup(I\setminus U_k)\\ &= \{(a_1,\ldots,a_n)\in I \mid P(a_1,\ldots,a_n) < 2^{-nH+k\cdot\sigma\sqrt{n}}\}\\ &\quad\cup\{(a_1,\ldots,a_n)\in I \mid P(a_1,\ldots,a_n) \geq 2^{-nH+k\cdot\sigma\sqrt{n}}\}. \end{aligned}$$

Temos então que

$$\begin{aligned} P(I) &= P(I\cap U_k) + P(I\setminus U_k)\\ &\leq |I|\cdot 2^{-n\cdot(H-2\frac{\sigma}{\sqrt{\delta n}})} + \frac{\delta}{4}\\ &\leq 2^{-2\frac{\sigma\sqrt{n}}{\sqrt{\delta}}} + \frac{\delta}{4} \leq \delta/2. \end{aligned}$$

que é menor que $\delta/2$ para todo o n suficientemente grande.

□